

GovSpend

WhiteCube AI Talent Academy

Trilha: Machine Learning

A Base de Dados – Cartão de Pagamento do Governo Federal (CPGF)



Órgãos de Governo | Acesso à Informação | Legislação | Acessibilidade | A+ A- ⓘ

☰ Portal da Transparência
Controladoria-Geral da União

O que você procura? 🔍

[🏠](#) > [Dados Abertos](#) > [Planilhas](#)

Exercícios Disponíveis

2026 ▼

Meses Disponíveis em 2026

JANEIRO ▼

Baixar

O Problema

- A Lei da Transparência (Lei Complementar nº 131/2009) obriga a União, os Estados, o Distrito Federal e os Municípios a divulgarem receitas e despesas públicas em tempo real na internet.
- Por causa do volume grande dos dados disponibilizados, a fiscalização das despesas, monitoramento de transações suspeitas ou elenco de prioridades por parte dos auditores são lentas, custosas e ineficientes

Proposta de Solução

- **GovSpenders:** um sistema inteligente focado na auditoria de despesas públicas. Ele utiliza modelos de Machine Learning não supervisionados para monitorar, mapear e identificar fraudes ou desvios no uso de cartões corporativos governamentais.

Funcionamento

O sistema analisa os dados de transações sob duas perspectivas diferentes e depois cruza as informações para gerar o resultado final:


- **Segmentação (K-Means):** Agrupa os gastos por padrões de consumo. Isso ajuda a entender o comportamento normal de compras e a separar os gastos por categorias ou perfis de usuários.
- **Detecção de Anomalias (Isolation Forest):** Analisa o histórico para isolar e identificar transações que fogem completamente do padrão esperado (gastos atípicos).

Resultado Pretendido

GovSpenders realiza um cruzamento inteligente entre os grupos mapeados e as anomalias detectadas. Essa correlação filtra o ruído dos dados e entrega um relatório direto com as 10 transações mais suspeitas, permitindo que os auditores foquem seus esforços onde o risco de fraude é crítico.

GovSpender:

GovSpender: Fluxo Operacional de Machine Learning



ETL

Diagnóstico da Base de Dados

- **Total de Linhas (Registros): 21.891**
- **Total de Colunas: 15**

Diagnóstico da Base de Dados

	COLUNA (VARIÁVEL)	TIPO DE DADO	QTD. NULOS	% NULOS	VALORES ÚNICOS
1.	CÓDIGO ÓRGÃO SUPERIOR	int64	0	0.00000	29
2.	NOME ÓRGÃO SUPERIOR	object	0	0.00000	28
3.	CÓDIGO ÓRGÃO	int64	0	0.00000	171
4.	NOME ÓRGÃO	object	0	0.00000	170
5.	CÓDIGO UNIDADE GESTORA	int64	0	0.00000	887
6.	NOME UNIDADE GESTORA	object	0	0.00000	860
7.	ANO EXTRATO	int64	0	0.00000	1
8.	MÊS EXTRATO	int64	0	0.00000	1
9.	CPF PORTADOR	object	5934	27.10703	2809
10.	NOME PORTADOR	object	0	0.00000	2811
11.	CNPJ OU CPF FAVORECIDO	int64	0	0.00000	8654
12.	NOME FAVORECIDO	object	0	0.00000	7996
13.	TRANSAÇÃO	object	0	0.00000	5
14.	DATA TRANSAÇÃO	object	5934	27.10703	31
15.	VALOR TRANSAÇÃO	object	0	0.00000	8106

Diagnóstico da Base de Dados

Index/ID	CÓDIGO ÓRGÃO SUPERIOR	NOME ÓRGÃO SUPERIOR	CÓDIGO ÓRGÃO	NOME ÓRGÃO	CÓDIGO UNIDADE GESTORA	NOME UNIDADE GESTORA	ANO EXTRATO	MÊS EXTRATO	CPF PORTADOR	NOME PORTADOR	CNPJ OU CPF FAVORECIDO	NOME FAVORECIDO	TRANSAÇÃO	DATA TRANSAÇÃO	VALOR TRANSAÇÃO
0	63000	Advocacia-Geral da União	63000	Advocacia-Geral da União - Unidades Unidades com vincul...	110161	SUPERINTENOE NCIA REG. DE ADMIN. DA 1ª REGIAO	2025	12	***.562.861-**	ANTONIO CARLOS MELO DOS SANTOS	6162854000150	CARTORIO DO 4. OFICIO DE NOTAS NOTAS DO DISTRITO FED...	COMPRA A/V - R\$ - APRES	14/11/2025	19,43
1	63000	Advocacia-Geral da União	63000	Advocacia-Geral da União - Unidades com vincul...	110161	SUPERINTENDE NCIA REG. DE ADMIN. DA 1ª REGIAO	2025	12	***.327.101-**	FELIPE MOREIRA GAIA	19468242000132	IFOOD PAGO INSTITUICAO DE PAGAMENTO S.A.	COMPRA A/V - R\$ - APRES	10/11/2025	256,00
2	63000	Advocacia-Geral da União	63000	Advocacia-Geral da União - Unidades com vincul...	110161	SUPERINTENDEN CIA REG. DE ADMIN. 2025 DA 1ª REGIAO		12	***.327.101-**	FELIPE MOREIRA GAIA	11000062000181	CASTELLI MATERIAIS PARA CONSTRUCAO LTDA	COMPRA A/V - R\$ - APRES	07/11/2025	109,90

Uma Questão de Governança de Dados

- Necessidade de Padronização e normalização dos Dados
- Necessidade de adequação às boas práticas do do DAMA-DMBOK, de Privacy By Design, LGPD e Constituição Federal de 1988
- A Presença dos dados de CPF na base de Dados
 - Pode gerar questionamento de enviesamento do Modelo de Machine Learning
 - Pode ferir o princípio da Impessoalidade da Administração Pública
 - Preocupação com a segurança dos dados e prevenção de vazamentos

Uma Questão de Governança de Dados

- **Solução: Adoção de Arquitetura Medalhão**
- Arquitetura dividida em 3 camadas: **Bronze, Silver e Gold**
- Emulação de Data Lake a partir de Um repositório do Github

Camada Bronze

- Manutenção da Base Bruta
- Acesso Restrito à pessoas autorizadas

Camada Silver

Higienização de dados para transformar o acervo bruto do CPGF em uma base confiável e segura para análise

- **Tratamento de Nulos:** Preenchimento de ausentes com padronizadores (NAO INFORMADO, 0, 00).
- **Padronização de Strings:** `.strip()`, remoção de caracteres de controle e conversão para caixa alta (UPPERCASE).
- **Parsing de Tipos:** Conversão de valores monetários para `float` e datas para `datetime`.
- **Privacy by Design:** Pseudonimização via hashing criptográfico (SHA-256) sobre os CPFs/CNPJs do portador e favorecido
- **Agregadores & Categorias:** Categorização explícita (COMPRA, SAQUE, SIGILO) e flags temporais de fim de semana.

Camada Silver


Resultado: O pipeline padronizou os tipos de dados (conversão de valores financeiros para numérico e datas para *timestamp*), isolou 5.934 registros categorizados sob sigilo legal para auditoria segregada e aplicou uma função hash criptográfica (SHA-256) na coluna de CPF dos portadores, descaracterizando informações pessoalmente identificáveis (PII) antes da exportação final em formato Parquet.

Camada Gold

- Agrupamento comportamental por `HASH_CPF_PORTADOR` gerando métricas de volume, ticket médio, volatilidade (`STD`), % de saques, % de compras e % de sigilo.
- Aplicação de **Log Transformation** (`np.log1p`) e normalização por **RobustScaler** para alimentar o Scikit-Learn.

RESULTADO

- Exportação e criação dos arquivos .parquet em Camadas Bronze, Silver e Gold em suas respectivas bases
- Criação de Dicionário de Dados de cada camada
- Criação de Relatório e Guia de Arquitetura



Modelos de Machine Learning

Segmentação K-Means


Segmentação K-Means

Modelo não supervisionado agrupa os portadores com base em métricas normalizadas de volume total e ticket médio, dividindo-os em três perfis intuitivos de **baixo consumo (0)**, **gastos moderados (1)** e **alto consumo (2)**

Divisão de Perfis

- Simplificação: mapeamento de Gradação Simples de quantificação de padrão de consumo entre baixo, médio e alto
- Equilíbrio de interpretabilidade, precisão estatística e isolamento de melhor clareza
- Evitar extrema fragmentação de perfis
- Validação matemática pela Avaliação de Hiperparâmetros pelo Método do Cotovelo e do Score de Silhueta, garantindo o equilíbrio perfeito entre a interpretabilidade e a precisão estatística para isolar o segmento de maior expressão financeira sem fragmentar excessivamente a análise

Validação de Hiperparâmetros: Método do Cotovelo vs Silhueta



Treinamento

1. Seleção de Variáveis (X)
2. Treinamento do K-Means (fit_predict)
3. Padronização Lógica das Etiquetas (Mapeamento Inteligente)
4. Exibição da Distribuição (value_counts)

Resultados

Distribuição dos CPFs por Perfil de Consumo:


cluster_kmeans

0 423

1 1377

2 1010

Segmentação de CPFs por Perfil de Consumo (K-Means)




Isolation Forest

Isolation Forest

- Tem como objetivo detectar portadores com comportamentos atípicos ou indícios de desvios na base de dados de gastos públicos.
- **Taxa de contaminação de 1%:** validada numericamente na fase de avaliação de hiperparâmetros por meio da análise do escore bruto de anomalia (função de decisão) e da extração de percentis estatísticos, mapeando com precisão o início da cauda de comportamento atípico e analisando variáveis como volatilidade, saques e sigilo.

Distribuição Contínua do Escore de Anomalia (Isolation Forest)



Treinamento

1. Seleção de Variáveis
2. Treinamento do Modelo (Isolation Forest)
3. Tradução da lógica do alerta
4. Visualização do Comportamento Atípico
5. Auditoria dos Casos Isolados


Resultados

alerta_fraude

False 2781

True 29

Mapeamento de portadores: Volume vs Ticket Médio



Cruzamento de resultados

Cruzamento de resultados

- O Elefante na sala: isolar apenas os volumes altos de consumo ou apenas anomalias, geram muitos falsos positivos
- A união do resultado do cluster K-means=2 (alto consumo) com o resultado booleano do Isolation Forest, que identifica as observações estatisticamente atípicas (`alerta_fraude == True`).
- Aplicação de operação lógica do tipo "E" (&)
- Gera nova coluna `transacao_suspeita`, atribuindo valor binário (1 para verdadeiro e 0 para falso) apenas aos registros que preenchem simultaneamente ambas as condições: pertencer ao perfil de maior volume de gastos e apresentar comportamento anômalo mapeado pelo isolamento.

Resultado

Total de registros na base: 2810

Total de CPFs Altamente Suspeitos (Cluster 2 + Anomalia IF): 11
(0.39% da base)

Relatório Final

- Criação de relatório executivo contendo as 10 transações mais suspeitas em PDF que será automaticamente exportado na pasta de Documentação
- O relatório será enviado para o auditor que irá decidir como realizar o procedimento investigativo.
- Os resultado desse sistema apontam apenas suspeitas e alertas, nunca uma decisão final, que deverá ser humana

Relatório de Auditoria: Transações e Portadores Suspeitos

Cruzamento de Modelos: K-Means (Perfil de Alto Gasto) + Isolation Forest (Anomalias Comportamentais)

Resumo Executivo da Auditoria

Este relatório consolida os resultados do cruzamento analítico entre a segmentação de perfis de consumo (K-Means) e a detecção estatística de desvios (Isolation Forest). O foco da auditoria recai sobre os portadores classificados simultaneamente no grupo de maior expressão financeira (Cluster 2 - Gasta Muito) e identificados como comportamentos anômalos pelo modelo de isolamento. Abaixo encontram-se os principais indicadores e a listagem dos casos prioritários para verificação de conformidade.

Tabela: Principais Portadores Prioritários para Investigação

Hash CPF Portador	Qtd Trans.	Volume Total	Ticket Médio	% Saques	% Sigilo
HASH_NAO...	5934	R\$ 7,871,500.64	R\$ 1,326.51	0.0%	100.0%
bef51bb3...	30	R\$ 63,429.90	R\$ 2,114.33	20.0%	0.0%
53bc0c4e...	38	R\$ 38,000.00	R\$ 1,000.00	100.0%	0.0%
8e47d2a4...	28	R\$ 27,800.00	R\$ 992.86	100.0%	0.0%
3e1e5868...	16	R\$ 20,950.76	R\$ 1,309.42	100.0%	0.0%
eda59412...	20	R\$ 20,000.00	R\$ 1,000.00	100.0%	0.0%
5d6b50db...	15	R\$ 14,990.00	R\$ 999.33	100.0%	0.0%
6495178e...	11	R\$ 10,999.27	R\$ 999.93	90.9%	0.0%
703c688c...	8	R\$ 9,790.78	R\$ 1,223.85	100.0%	0.0%
b6340de8...	9	R\$ 9,000.00	R\$ 1,000.00	100.0%	0.0%

Link do Repositório e Projeto completo

<https://github.com/joaohppenha/govspendertest/>

